

Laporan Komprehensif Capstone Project

SisaBisa

BAB I PENDAHULUAN

1.1. Latar Belakang

Food waste menjadi salah satu permasalahan global yang memberikan dampak besar terhadap lingkungan, ekonomi, dan ketahanan pangan. Di Indonesia, jumlah sampah makanan diperkirakan mencapai 23–48 juta ton per tahun dengan kontribusi terbesar berasal dari sektor rumah tangga (Bappenas, 2021). Tingginya angka *food waste* ini dipengaruhi oleh kebiasaan pembelian bahan makanan dalam jumlah besar tanpa pengelolaan stok yang optimal, sehingga banyak bahan makanan terlewat pemantauan dan berakhir kedaluwarsa sebelum digunakan (Thyberg & Tonjes, 2016).

Di sisi lain, sebagian besar aplikasi pengelolaan stok makanan yang tersedia saat ini masih berfungsi sebagai pencatat inventaris pasif tanpa kemampuan prediksi umur simpan, peringatan dini, maupun rekomendasi penggunaan bahan secara proaktif (Scherhauer et al., 2018). Akibatnya, pengguna masih kesulitan menentukan bahan mana yang perlu diprioritaskan untuk segera diolah guna mengurangi potensi pemborosan makanan.

Analisis data pada proyek ini berfokus pada pengaruh metode penyimpanan terhadap umur simpan bahan makanan, identifikasi kategori bahan yang paling cepat kedaluwarsa, serta pola penggunaan bahan pada resep Indonesia. Hasil analisis diharapkan dapat menjadi dasar dalam pengembangan sistem rekomendasi prioritas bahan dan resep yang mampu membantu rumah tangga Indonesia mengurangi *food waste* secara lebih efektif dan berkelanjutan.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, maka rumusan masalah pada proyek SisaBisa dirumuskan dalam bentuk pertanyaan bisnis sebagai berikut:

1. Berapa estimasi umur simpan rata-rata bahan makanan berdasarkan metode penyimpanan?
2. Kategori bahan mana yang paling cepat kedaluwarsa dan berisiko tinggi terbuang?
3. Apakah metode penyimpanan berpengaruh signifikan terhadap umur simpan bahan makanan?
4. Seberapa seimbang distribusi data per metode penyimpanan dan per kategori?
5. Bahan utama apa yang paling sering dipakai di resep?
6. Berapa rata-rata jumlah bahan per resep?

1.3. Tujuan Analisis

Tujuan dari analisis pada proyek SisaBisa adalah sebagai berikut:

1. Menganalisis estimasi umur simpan rata-rata bahan makanan berdasarkan metode penyimpanan.
2. Mengidentifikasi kategori bahan makanan yang paling cepat kedaluwarsa dan berisiko tinggi terbuang.
3. Menganalisis pengaruh metode penyimpanan terhadap umur simpan bahan makanan menggunakan pendekatan statistik.
4. Menganalisis distribusi data bahan makanan berdasarkan kategori dan metode penyimpanan untuk memastikan keseimbangan data.
5. Mengidentifikasi bahan utama yang paling sering digunakan dalam resep makanan Indonesia untuk mendukung sistem rekomendasi resep.

6. Menganalisis distribusi dan kompleksitas jumlah bahan pada resep makanan Indonesia.
7. Memberikan *insight* berbasis data untuk mendukung pengembangan sistem prioritas bahan dan pengurangan food waste rumah tangga.

1.4. Manfaat Analisis

Adapun manfaat yang diharapkan dari analisis pada proyek SisaBisa adalah sebagai berikut:

1. Membantu pengguna memahami estimasi umur simpan bahan makanan berdasarkan kategori dan metode penyimpanan.
2. Membantu menentukan prioritas penggunaan bahan makanan yang berisiko cepat kedaluwarsa sehingga dapat mengurangi potensi *food waste*.
3. Memberikan insight terkait metode penyimpanan yang paling efektif untuk memperpanjang umur simpan bahan makanan.
4. Mendukung pengembangan sistem rekomendasi resep berbasis bahan makanan yang tersedia di rumah tangga pengguna.
5. Memberikan pemahaman mengenai pola penggunaan bahan pada resep makanan Indonesia untuk mendukung pengembangan fitur rekomendasi resep berbasis AI.
6. Mendukung pengembangan sistem manajemen pangan rumah tangga yang lebih efisien, proaktif, dan berkelanjutan melalui pendekatan berbasis data.

BAB II DATA

2.1. Sumber Data

Dataset yang digunakan pada proyek SisaBisa berasal dari beberapa sumber yaitu:

1. Dataset Bahan: [Department of Agriculture - FSIS - FoodKeeper Data](#)

2. Dataset Resep: [Indonesian Food Recipes Dataset](#)

2.2. Dataset Bahan

Dataset bahan makanan digunakan untuk menganalisis estimasi umur simpan bahan berdasarkan kategori bahan dan metode penyimpanan. Dataset awal diperoleh dari data shelf life bahan makanan yang berisi informasi umur simpan pada berbagai kondisi penyimpanan seperti suhu ruangan, kulkas, dan *freezer*.

Dataset ini memiliki informasi terkait:

1. nama bahan makanan
2. kategori bahan
3. metode penyimpanan,
4. estimasi minimum dan maksimum masa kedaluwarsa
5. serta satuan waktu penyimpanan.

Pada tahap *preprocessing*, dataset mengalami proses *cleaning*, standarisasi satuan waktu, translasi bahasa, penghapusan duplikasi, dan *feature engineering* sehingga menghasilkan dataset final yang lebih terstruktur dan siap digunakan untuk analisis.

Dataset final bahan makanan terdiri dari 504 data masa kedaluwarsa, di mana terdapat 168 bahan dan 8 kategori bahan makanan dengan tiga metode penyimpanan.

2.3. Dataset Resep

Dataset resep digunakan untuk menganalisis pola penggunaan bahan makanan pada berbagai menu masakan serta sebagai dasar dalam pengembangan sistem rekomendasi resep dan pengelolaan bahan makanan. Dataset awal diperoleh dari kumpulan resep masakan yang memuat informasi detail mengenai

nama menu, daftar bahan, langkah memasak, jumlah likes, kategori resep, dan tautan resep.

Dataset ini memiliki informasi terkait:

1. Nama menu masakan (*title*),
2. Daftar bahan yang digunakan (*ingredients*),
3. Langkah-langkah memasak (*steps*),
4. Jumlah likes atau favorit resep (*loves*),
5. Kategori masakan (*category*),
6. Tautan resep (URL),
7. Total bahan dan total langkah,
8. Serta hasil pembersihan teks pada nama menu dan bahan masakan.

Pada tahap *preprocessing*, dataset mengalami proses *cleaning*, normalisasi teks, penghapusan karakter dan simbol yang tidak diperlukan, standarisasi penulisan bahan, penghapusan duplikasi, serta penggabungan dataset dari beberapa kategori bahan makanan. Selain itu, struktur data juga diubah menjadi format yang lebih terorganisir sehingga setiap menu masakan memiliki daftar bahan yang telah dibersihkan dan siap digunakan untuk analisis lebih lanjut.

Dataset final resep terdiri dari lebih dari 14 ribu data resep masakan dengan lebih dari 11 ribu variasi bahan makanan. Dataset ini mencakup berbagai kategori menu berbahan dasar ayam, sapi, ikan, telur, tahu, tempe, udang, dan kambing sehingga dapat digunakan untuk mendukung analisis pola penggunaan bahan makanan maupun pengembangan fitur rekomendasi resep berbasis teks.

BAB III DATA WRANGLING DAN PREPROCESSING

3.1. Gathering Data

Pada tahap *gathering* data, dataset bahan makanan diperoleh dari file spreadsheet yang disimpan pada Google Drive dan diakses menggunakan library requests dan pandas. Dataset kemudian dibaca dalam format Excel (.xlsx) dan dipisahkan berdasarkan sheet untuk memudahkan proses *preprocessing* dan analisis. Dataset bahan terdiri dari beberapa sheet utama, yaitu:

1. Product : data utama masa kedaluwarsa bahan makanan
2. Product_Translate : data hasil terjemahan dari sheet Product
3. Category : data kategori bahan makanan
4. Category_Translate: data hasil terjemahan dari sheet Category

Selain dataset bahan makanan, digunakan juga dataset resep yang diperoleh dari platform Kaggle dalam format CSV. Dataset resep berisi kumpulan resep masakan berdasarkan berbagai kategori bahan makanan seperti ayam, sapi, ikan, udang, telur, tahu, tempe, dan kambing. Dataset ini memuat informasi mengenai nama menu masakan, daftar bahan yang digunakan, langkah-langkah memasak, jumlah *likes* atau favorit resep, kategori masakan, serta tautan resep. Seluruh dataset resep kemudian dikumpulkan dan digunakan sebagai dasar dalam proses *preprocessing* untuk menghasilkan data yang lebih bersih, terstandarisasi, dan siap digunakan pada tahap analisis maupun pengembangan sistem rekomendasi resep.

Pada tahap ini, proses pengumpulan data dilakukan untuk memastikan seluruh dataset yang digunakan memiliki struktur data yang sesuai dan mendukung proses analisis pada tahap selanjutnya.

3.2. Assessing Data

3.2.1. Assessing Dataset Product

Hasil evaluasi menunjukkan bahwa dataset `df_product` memiliki beberapa permasalahan kualitas data. Ditemukan missing value dalam jumlah besar pada kolom penyimpanan seperti Pantry, Refrigerate, dan Freeze. Kondisi ini terjadi karena tidak semua bahan makanan memiliki informasi shelf life pada seluruh metode penyimpanan. Selain itu, ditemukan 2.645 nilai `#VALUE!` yang berasal dari error formula Excel. Nilai invalid tersebut menyebabkan beberapa kolom numerik terbaca sebagai tipe object, sehingga dapat mengganggu proses konversi umur simpan ke satuan hari. Dataset juga memiliki duplicate ID dan duplicate Name yang berpotensi menyebabkan redundansi data. Pada kolom metric ditemukan inkonsistensi format satuan waktu seperti Day, Week, Month, Year, hingga nilai tidak valid seperti Not Recommended. Apabila permasalahan tersebut tidak ditangani, maka hasil analisis umur simpan dapat menjadi tidak akurat dan menyebabkan bias pada sistem rekomendasi prioritas bahan.

3.2.2. Assessing Dataset Product Translate

Dataset `df_translate` memiliki struktur yang sama dengan `df_product`, namun menggunakan Bahasa Indonesia pada kolom nama bahan dan metric. Hasil *assessing* menunjukkan beberapa permasalahan berikut:

1. Terdapat *missing value* pada beberapa kolom penyimpanan.
2. Ditemukan 51 nilai `#VALUE!`.
3. Terdapat *duplicate* ID.
4. Kolom metric menggunakan Bahasa Indonesia seperti Hari, Minggu, Bulan, dan Tahun, sehingga perlu distandarisasi agar konsisten dengan dataset utama.

3.2.3. Assessing Dataset Category

Dataset kategori tidak memiliki *missing value* maupun duplicate data. Dataset ini digunakan untuk proses *mapping* kategori bahan makanan.

3.2.4. Assessing Dataset Resep

Hasil evaluasi menunjukkan bahwa dataset resep yang berasal dari beberapa file kategori bahan makanan, seperti dataset-ayam.csv, dataset-sapi.csv, dataset-ikan.csv, dataset-udang.csv, dataset-telur.csv, dataset-tahu.csv, dataset-tempe.csv, dan dataset-kambing.csv memiliki beberapa permasalahan kualitas data. Ditemukan inkonsistensi penulisan pada kolom *ingredients* dan *title*, seperti penggunaan huruf kapital yang tidak seragam, keberadaan angka, simbol, karakter khusus, serta satuan takaran yang masih tercampur dalam teks bahan makanan.

Selain itu, daftar bahan pada kolom *ingredients* masih berbentuk teks panjang dalam satu baris dengan pemisah tertentu sehingga struktur data belum terorganisir dengan baik untuk proses analisis. Beberapa bahan juga masih mengandung informasi tambahan seperti jumlah bahan, cara pemotongan, maupun keterangan memasak singkat yang menyebabkan data menjadi kurang konsisten antar dataset kategori.

Pada beberapa data juga ditemukan variasi penulisan nama menu maupun bahan yang berbeda meskipun merujuk pada objek yang sama. Kondisi tersebut berpotensi menimbulkan redundansi data dan mempersulit proses identifikasi bahan makanan pada tahap analisis. Apabila permasalahan tersebut tidak ditangani, maka proses pengolahan data resep dan pengembangan sistem rekomendasi dapat menghasilkan output yang kurang optimal karena data belum berada dalam format yang terstandarisasi.

3.3. Cleaning Data

3.3.1. Cleaning Dataset Bahan

Tahap *cleaning* data dilakukan untuk memperbaiki kualitas dataset bahan makanan sebelum digunakan pada proses analisis lanjutan. Berdasarkan hasil *assessing*, dataset masih memiliki beberapa permasalahan seperti nilai invalid *#VALUE!*, tipe data numerik yang belum sesuai, *duplicate* data, satuan waktu yang belum seragam, serta format data yang belum siap digunakan untuk analisis umur simpan.

Proses *cleaning* pertama dilakukan pada dataset awal melalui fungsi ``clean_base()``. Pada tahap ini, seluruh nilai *#VALUE!* diganti menjadi NaN agar dapat diproses dengan lebih aman oleh pandas. Berdasarkan hasil output, terdapat 2.645 sel yang berhasil diganti dari *#VALUE!* menjadi NaN. Setelah itu, sebanyak 18 kolom yang berisi nilai minimum dan maksimum umur simpan dikonversi ke tipe data numerik agar dapat digunakan dalam perhitungan statistik.

Selain penanganan nilai invalid dan tipe data, dilakukan juga standardisasi nama bahan dengan mengubah teks menjadi huruf kecil dan menghapus spasi berlebih. Pemeriksaan terhadap nama bahan kosong menunjukkan bahwa tidak ada baris yang dihapus pada tahap ini. Selanjutnya, *duplicate* berdasarkan kolom ID dihapus untuk menghindari pengulangan data bahan. Dari proses ini, terdapat 27 baris *duplicate* ID yang berhasil dihapus sehingga jumlah data tersisa menjadi 169 baris.

Setelah data dasar dibersihkan, dilakukan proses transformasi data menggunakan fungsi `build_clean()`. Fungsi ini mengambil nilai umur simpan terbaik dari beberapa kolom penyimpanan, dengan memprioritaskan nilai maksimum apabila tersedia. Data penyimpanan kemudian dikelompokkan menjadi tiga metode utama, yaitu Room Temperature, Fridge, dan Freezer.

Pada tahap ini, satuan waktu seperti hari, minggu, bulan, dan tahun dikonversi menjadi satuan yang seragam, yaitu hari. Konversi dilakukan menggunakan fungsi `convert_days()`, di mana minggu dikalikan 7, bulan dikalikan 30, dan tahun dikalikan 365. Nilai dengan satuan Not Recommended atau Tidak Disarankan tidak digunakan karena tidak merepresentasikan estimasi umur simpan yang valid.

Setelah umur simpan dikonversi ke satuan hari, dilakukan filtering terhadap nilai outlier. Data hanya dipertahankan jika nilai *days* berada pada rentang 0 hingga kurang dari 3650 hari. Berdasarkan hasil output, tidak terdapat outlier yang dihapus pada tahap ini. Selanjutnya, *duplicate* berdasarkan kombinasi item dan *storage* dihapus agar setiap bahan hanya memiliki satu nilai umur simpan untuk setiap metode penyimpanan. Proses ini menghapus 3 baris *duplicate* tambahan.

Dataset awal yang telah dibersihkan kemudian digunakan sebagai dasar untuk membentuk dataset *translate*. Nama bahan diterjemahkan menggunakan *mapping* dari `df_translate`, sedangkan nama *storage* diubah menjadi Bahasa Indonesia melalui `storage_map`. Selain itu, kategori bahan juga distandarisasi menggunakan `category_map` manual agar kategori pada dataset final menjadi lebih konsisten dan mudah dipahami.

Pada tahap akhir, dataset dikelompokkan berdasarkan kombinasi *category*, *item*, dan *storage*. Jika masih terdapat lebih dari satu nilai umur simpan untuk kombinasi yang sama, maka nilai *minimum days* digunakan untuk mengambil estimasi umur simpan yang lebih konservatif. Setelah itu, dibuat `ingredient_id` sebagai ID unik untuk setiap bahan makanan, sedangkan kolom `id` dibuat ulang sebagai ID unik untuk setiap baris data final.

Hasil akhir *cleaning* menghasilkan dataset bersih dengan kolom `id`, `ingredient_id`, `category`, `item`, `storage`, dan `days`. Dataset final kemudian disimpan

dalam format Excel (fix_bahan_clean.xlsx) dan CSV (fix_bahan_clean_translate.csv) sehingga siap digunakan untuk tahap *feature engineering*, *exploratory data analysis*, visualisasi dashboard, dan pengembangan fitur prioritas bahan berdasarkan estimasi masa kedaluwarsa.

3.3.2. Cleaning Dataset Resep

Tahap *cleaning* data dilakukan untuk memperbaiki kualitas dataset resep sebelum digunakan pada proses analisis lanjutan dan pengembangan sistem rekomendasi. Berdasarkan hasil *assessing*, dataset resep masih memiliki beberapa permasalahan seperti inkonsistensi penulisan bahan makanan, keberadaan angka dan satuan takaran pada kolom *ingredients*, karakter dan simbol yang tidak diperlukan, serta struktur data bahan yang masih berbentuk teks panjang dalam satu baris. Selain itu, terdapat variasi penulisan nama menu dan bahan makanan yang berpotensi menyebabkan redundansi data pada tahap analisis.

Proses *cleaning* pertama dilakukan pada masing-masing dataset kategori bahan makanan seperti ayam, sapi, ikan, udang, telur, tahu, tempe, dan kambing secara terotomatisasi menggunakan perulangan Python. Pada tahap ini, dilakukan pengambilan sampel data secara acak menggunakan parameter `random_state=42` dengan jumlah maksimum 1850 data pada setiap dataset untuk menjaga konsistensi dan keseimbangan data.

Setelah proses *sampling*, kolom *ingredients* diubah menjadi format long-form menggunakan fungsi `explode()`, sehingga setiap bahan makanan dalam satu resep dipisahkan menjadi baris tersendiri. Langkah ini dilakukan agar proses pembersihan teks pada setiap bahan dapat dilakukan dengan lebih mudah dan terstruktur.

Tahap berikutnya adalah pembersihan teks menggunakan Regular Expression (RegEx). Pada proses ini, angka, simbol, karakter non-alfabet, serta

kata-kata satuan takaran seperti gram, sdm, siung, ml, dan lainnya dihapus dari data bahan makanan. Selain itu, teks bahan juga disederhanakan dengan mengambil dua kata pertama untuk mengurangi *noise* berupa instruksi tambahan seperti cara pemotongan atau keterangan memasak.

Setelah proses *filtering* selesai, dilakukan penghapusan baris kosong dan data yang tidak valid hasil proses *cleaning*. Dataset hasil pembersihan dari masing-masing kategori kemudian disimpan dalam format Excel sebelum dilakukan proses penggabungan data.

Tahap selanjutnya adalah penggabungan seluruh dataset hasil *cleaning* menggunakan fungsi `pd.concat()` sehingga membentuk satu dataset master resep. Pada tahap ini dilakukan standarisasi nama kolom menjadi huruf kecil untuk menghindari error saat proses *merging*. Selain itu, judul resep juga dibersihkan dari tanda petik, karakter khusus, dan spasi berlebih agar format penulisan menu menjadi lebih konsisten.

Setelah seluruh data tergabung, dilakukan reorganisasi struktur data dari *long format* menjadi *wide format* menggunakan proses *group by* berdasarkan nama menu masakan. Seluruh bahan dari resep yang sama digabungkan kembali ke dalam satu baris dengan pemisah koma. Pada tahap ini juga digunakan fungsi `unique()` untuk menghapus duplikasi bahan yang identik dalam satu resep.

Tahap akhir *cleaning* dilakukan dengan membersihkan kembali sisa angka maupun simbol pada nama menu dan daftar bahan menggunakan RegEx. Hasil akhir *cleaning* menghasilkan dataset resep dengan struktur 1 menu = 1 baris dan daftar bahan yang telah bersih, terstandarisasi, serta siap digunakan untuk proses *exploratory data analysis*, visualisasi, maupun pengembangan sistem rekomendasi resep berbasis bahan makanan.

3.4. Feature Engineering

Feature Engineering dilakukan untuk menghasilkan representasi fitur yang lebih informatif dan siap digunakan untuk analisis lanjutan maupun pengembangan model *machine learning*. Dataset yang digunakan adalah `fix_bahan_clean_translate.csv` yang telah melalui proses *cleaning* dan standarisasi. Terdapat tiga jenis *feature engineering* yang dilakukan pada dataset bahan makanan SisaBisa, yaitu *encoding* untuk metode penyimpanan, transformasi logaritmik untuk umur simpan, dan *one-hot encoding* untuk variabel kategorikal.

1. Encoding Ordinal pada Storage Level

Fitur *storage level* dibuat untuk merepresentasikan metode penyimpanan dalam bentuk nilai numerik yang bersifat ordinal. Pendekatan ini dipilih karena ketiga metode penyimpanan memiliki hubungan hierarkis yang jelas terhadap efektivitasnya dalam memperpanjang umur simpan bahan makanan dimana *freezer* lebih efektif dari kulkas, dan kulkas lebih efektif dari suhu ruangan

Tabel 3.1 *Mapping Encoding Ordinal Metode Penyimpanan*

Metode Penyimpanan	storage_level	Alasan
Suhu Ruangan	1	Penyimpanan paling tidak efektif, umur simpan terpendek
Kulkas	2	Penyimpanan menengah, memperlambat pertumbuhan bakteri

Freezer	3	Penyimpanan paling efektif, umur simpan terpanjang
---------	---	---

Encoding ordinal dipilih dibanding *one-hot encoding* untuk fitur ini karena terdapat urutan yang bermakna (*ordered*) antar nilai — *freezer* > kulkas > suhu ruangan dalam hal efektivitas penyimpanan. Penggunaan *one-hot encoding* pada variabel ini justru akan menghilangkan informasi urutan tersebut.

2. Transformasi Logaritmik pada Days_Log

Fitur `days_log` merupakan hasil transformasi logaritmik dari kolom *days* (umur simpan dalam hari) menggunakan fungsi $\log(1 + x)$ atau $\log_{1p}$. Transformasi ini dilakukan untuk menangani distribusi data umur simpan yang sangat *right-skewed* akibat perbedaan rentang nilai yang besar antar bahan makanan.

Tabel 3.2 Perbandingan Statistik Sebelum dan Sesudah Transformasi Logaritmik

Statistik	days (original)	days_log (setelah transformasi)
Min	1 hari	~0,69
Median	30 hari	~3,43
Mean	147,1 hari	~3,81
Max	1.440 hari	~7,27
Standar Deviasi	211,9 hari	lebih kecil

Transformasi $\log_{1p}$ dipilih karena aman digunakan pada nilai 0 ($\log(1+0) = 0$), berbeda dengan log biasa yang tidak terdefinisi untuk nilai 0. Setelah transformasi, distribusi data menjadi lebih mendekati normal sehingga lebih sesuai digunakan sebagai target variabel dalam model *machine learning*.

3. One-Hot Encoding pada Kategori Bahan dan Metode Penyimpanan

One-hot encoding diterapkan pada dua kolom kategorikal, yaitu kategori bahan makanan dan metode penyimpanan. Teknik ini mengubah setiap nilai unik dalam kolom kategorikal menjadi kolom biner tersendiri bernilai 0 atau 1, sehingga dapat digunakan oleh algoritma *machine learning* yang membutuhkan input numerik.

Tabel 3.3 Hasil *One-Hot Encoding* pada Kolom Kategorikal

Kolom Asal	Jumlah Nilai Unik	Jumlah Kolom Baru	Contoh Kolom Hasil
Kategori Bahan	8 kategori	8 kolom	category_sayuran, category_daging, ...
Metode Penyimpanan	3 metode	3 kolom	storage_freezer, storage_kulkas, ...

Parameter `handle_unknown='ignore'` digunakan agar *encoder* tidak mengalami error jika pada saat inferensi ditemukan nilai kategori yang tidak ada di data training. Hasil *encoding* disimpan sebagai objek `encoder.pkl` menggunakan *library* `joblib` sehingga dapat digunakan kembali tanpa perlu melakukan *fitting* ulang.

4. Standarisasi Fitur

Setelah seluruh fitur selesai dibentuk, dilakukan standarisasi menggunakan StandardScaler dari *library* scikit-learn. Proses ini mengubah setiap fitur sehingga memiliki rata-rata 0 dan standar deviasi 1. Standarisasi diperlukan agar fitur dengan rentang nilai besar seperti *storage_level* tidak mendominasi fitur lain dalam proses pembelajaran model. Hasil *scaler* juga disimpan sebagai objek *scaler.pkl* menggunakan *joblib* agar dapat digunakan secara konsisten pada tahap inferensi maupun *deployment*.

Feature engineering yang dilakukan pada dataset bahan makanan menghasilkan empat jenis fitur tambahan yang merepresentasikan informasi penyimpanan dan umur simpan dalam format yang lebih sesuai untuk analisis dan pemodelan.

- *storage_level* merepresentasikan hierarki efektivitas metode penyimpanan secara ordinal (1=Suhu Ruangan, 2=Kulkas, 3=Freezer), memungkinkan model untuk memahami urutan efektivitas penyimpanan.
- *days_log* mengurangi *skewness* distribusi umur simpan melalui transformasi logaritmik sehingga distribusi data menjadi lebih mendekati normal dan lebih stabil untuk digunakan sebagai target variabel.
- *One-hot encoding* pada kategori bahan dan metode penyimpanan mengubah variabel kategorikal menjadi representasi numerik biner yang dapat diproses oleh algoritma *machine learning*.
- Standarisasi menggunakan StandardScaler memastikan seluruh fitur berada pada skala yang sebanding sehingga tidak ada fitur yang mendominasi proses pembelajaran model.

Seluruh objek *encoder* dan *scaler* disimpan dalam format *pickle* (.pkl) untuk memastikan konsistensi transformasi antara tahap pelatihan dan inferensi pada sistem SisaBisa.

3.5. Data Dictionary

Data dictionary merupakan dokumentasi yang menjelaskan setiap atribut (kolom) yang terdapat dalam dataset yang digunakan pada proyek SisaBisa. Dokumentasi ini mencakup dua dataset utama, yaitu dataset bahan makanan dan dataset resep.

1. Dataset Bahan

Dataset bahan terdiri dari 504 baris data yang merepresentasikan 168 bahan unik dengan tiga metode penyimpanan masing-masing.

Tabel 3.4 Data Dictionary Dataset Bahan Makanan

No	Kolom	Tipe Data	Deskripsi
1.	id	int	ID unik untuk setiap baris data
2.	ingredient_id	int	ID unik untuk setiap bahan makanan (satu bahan memiliki tiga baris sesuai metode penyimpanan)
3.	category	object	Kategori bahan makanan (8 kategori: Sayuran, Daging, Hidangan Laut, dll)
4.	item	object	Nama bahan makanan dalam Bahasa Indonesia yang telah distandarisasi

5.	storage	object	Metode penyimpanan bahan makanan (Freezer, Kulkas, Suhu Ruangan)
6.	days	int	Estimasi umur simpan bahan makanan dalam satuan hari

Penjelasan kolom-kolom pada dataset bahan:

- Id: Kolom id digunakan sebagai identitas unik setiap baris pada dataset final.
- Ingredient_id: Kolom ingredient_id merepresentasikan identitas unik setiap bahan makanan. Berbeda dengan id, satu ingredient_id dapat muncul tiga kali dalam dataset karena setiap bahan memiliki data umur simpan untuk ketiga metode penyimpanan (Freezer, Kulkas, Suhu Ruangan).
- Category: Kolom category digunakan untuk mengelompokkan bahan makanan berdasarkan jenisnya. Terdapat 8 kategori dalam dataset, yaitu Sayuran, Bumbu/Saus & Makanan Kalengan, Hidangan Laut, Daging, Makanan Tahan Lama di Rak, Produk Susu & Telur, Buah-buahan, serta Biji-bijian/Kacang-kacangan & Pasta.
- Item: Kolom item menyimpan nama bahan makanan.
- Storage: Kolom storage menunjukkan metode penyimpanan bahan makanan. Terdapat tiga nilai: Freezer, Kulkas, dan Suhu Ruangan. Atribut ini menjadi salah satu variabel utama dalam analisis karena setiap metode penyimpanan memiliki pengaruh yang berbeda terhadap umur simpan bahan makanan.
- Days: Kolom days merupakan atribut numerik yang menyimpan estimasi umur simpan bahan makanan dalam satuan hari. Seluruh

nilai umur simpan telah dikonversi ke format numerik dan diseragamkan ke satuan hari dari berbagai satuan waktu asal.

2. Dataset Resep

Dataset resep merupakan dataset yang berisi kumpulan resep makanan Indonesia beserta daftar bahan yang digunakan. Dataset ini digunakan untuk analisis frekuensi penggunaan bahan pada masakan Indonesia dan mendukung pengembangan sistem rekomendasi resep pada SisaBisa.

Tabel 3.5 Data Dictionary Dataset Resep Indonesia

No	Kolom	Tipe Data	Deskripsi
1.	nama_menu	object	Nama resep atau menu makanan Indonesia
2.	bahan	object	Daftar bahan resep dalam bentuk teks asli sebelum diproses
3.	bahan_list	object	Daftar bahan resep yang telah dipisahkan dan disimpan dalam format list untuk memudahkan analisis frekuensi bahan

Penjelasan kolom-kolom pada dataset resep:

- Nama_menu: kolom nama_menu digunakan untuk menyimpan informasi nama resep. Kolom ini berfungsi sebagai identitas utama setiap resep dalam dataset.

- Bahan: Kolom bahan berisi daftar bahan resep dalam bentuk teks asli sebelum melalui proses *preprocessing*. Format kolom ini masih berupa string panjang yang mencantumkan seluruh bahan dalam satu teks.
- Bahan_list: Kolom bahan_list merupakan hasil *preprocessing* dari kolom bahan. Daftar bahan telah dipisahkan dan disimpan dalam format list sehingga setiap elemen merepresentasikan satu bahan.

BAB IV. EXPLORATORY DATA ANALYSIS (EDA)

4.1. Statistika Deskriptif Umur Simpan

Analisis statistik deskriptif dilakukan untuk memahami karakteristik umum data umur simpan bahan makanan, seperti nilai minimum, maksimum, rata-rata, median, dan standar deviasi.

Tabel 4.1 Statistika Deskriptif Umur Simpan Bahan

Statistik	Nilai
Count	504
Mean	147.1
Standar Deviasi	211.9
Min	1
Quartil 1	3
Median	30
Quartil 3	180
Max	1440

Berdasarkan statistik deskriptif, dataset memiliki rentang umur simpan yang cukup besar, mulai dari 1 hari hingga 1440 hari. Nilai median sebesar 30 hari menunjukkan bahwa sebagian besar bahan makanan memiliki umur simpan relatif pendek hingga menengah. Sementara itu, nilai standar deviasi yang cukup tinggi mengindikasikan adanya variasi umur simpan yang besar antar bahan makanan dan metode penyimpanan.

4.2. Distribusi Bahan

Untuk memahami karakteristik dataset bahan makanan, dilakukan eksplorasi terhadap distribusi metode penyimpanan dan kategori bahan makanan. Analisis ini bertujuan untuk melihat persebaran data pada setiap kategori metode penyimpanan serta mengetahui kategori bahan yang paling banyak terdapat dalam dataset.

Tabel 4.2 Jumlah Bahan per Metode Penyimpanan

Metode Penyimpanan	Jumlah Data
Freezer	168
Kulkas	168
Suhu Ruangan	168
Total	504

Tabel 4.3 Jumlah Bahan per Kategori

Kategori Bahan	Jumlah Data
Sayuran	177

Kategori Bahan	Jumlah Data
Bumbu, Saus & Makanan Kalengan	78
Hidangan laut	75
Daging	42
Makanan Tahan Lama di Rak	39
Produk Susu & Telur	39
Buah-buahan	33
Biji-bijian, Kacang-kacangan & Pasta	21

Berdasarkan hasil eksplorasi data, distribusi metode penyimpanan pada dataset bersifat seimbang karena setiap bahan makanan direpresentasikan ke dalam tiga metode penyimpanan utama, yaitu *freezer*, kulkas, dan suhu ruangan. Selain itu, kategori sayuran menjadi kategori dengan jumlah data terbanyak dibanding kategori lainnya. Secara keseluruhan, dataset akhir terdiri dari 8 kategori bahan makanan dan 168 bahan unik yang telah melalui proses *cleaning* dan standarisasi data.

4.3. Distribusi Umur Simpan Bahan per Metode Penyimpanan

Analisis distribusi umur simpan per metode penyimpanan dilakukan untuk membandingkan bagaimana penyimpanan di suhu ruangan, kulkas, dan *freezer* mempengaruhi ketahanan bahan makanan.

Tabel 4.4 Distribusi Umur Simpan Bahan per Metode Penyimpanan

Storage	Rata-Rata	Median	Standar Deviasi	Min	Max	Jumlah
Suhu Ruangan	61.5	2	147.4	1	999	168
Kulkas	94.8	7	177.7	1	999	168
Freezer	285	180	229.6	14	1440	168

Berdasarkan distribusi umur simpan, *freezer* secara konsisten memberikan umur simpan paling panjang dengan median 180 hari, jauh lebih tinggi dibanding kulkas (7 hari) dan suhu ruangan (2 hari). Perbedaan ekstrem ini menunjukkan bahwa metode penyimpanan merupakan faktor krusial dalam memperpanjang ketahanan pangan, di mana pembekuan efektif menghentikan pembusukan sementara suhu ruang sangat mempercepatnya. Adapun tingginya nilai rata-rata dan standar deviasi pada data dipicu oleh kemiringan data ke kanan (*right-skewed*) akibat keberadaan angka maksimum ekstrem (999 dan 1440 hari) yang berfungsi sebagai *placeholder* statistik untuk komoditas kering yang awet selamanya.

4.4. Distribusi Umur Simpan Bahan per Kategori Bahan

Analisis distribusi umur simpan per kategori bahan dilakukan untuk membandingkan bagaimana kelompok komoditas yang berbeda (seperti daging, sayuran, produk susu, dll) mempengaruhi ketahanan bahan makanan.

Tabel 4.5 Distribusi Umur Simpan Bahan per Kategori Bahan

Kategori Bahan	Rata-Rata	Median	Min	Max	Jumlah
Sayuran	73.9	2	1	540	75
Bumbu, Saus & Makanan Kalengan	72.1	3	1	360	42
Hidangan laut	78	14	1	540	177
Daging	81.7	14	2	360	33
Makanan Tahan Lama di Rak	91.9	30	1	365	39
Produk Susu & Telur	292.2	180	1	730	31
Buah-buah an	238.5	180	1	730	78
Biji-bijian, Kacang-kac angan &	532	365	30	1440	39

Kategori Bahan	Rata-Rata	Median	Min	Max	Jumlah
Pasta					

Berdasarkan nilai tengah atau median, kelompok Makanan Tahan Lama di Rak memiliki daya simpan tertinggi (365 hari), diikuti oleh produk kering dan olahan seperti Bumbu, Saus & Makanan Kalengan serta Biji-bijian, Kacang-kacangan & Pasta (180 hari). Sebaliknya, kelompok komoditas segar seperti Daging (3 hari) dan Hidangan laut (2 hari) memiliki median umur simpan terendah, yang menunjukkan kerentanan tinggi terhadap pembusukan. Lonjakan nilai rata-rata yang jauh melampaui median di semua kategori mengonfirmasi bahwa distribusi data miring ke kanan (*right-skewed*), dipicu oleh nilai maksimum ekstrem (seperti 540, 730, hingga 1440 hari) yang bertindak sebagai *placeholder* statistik untuk produk tertentu yang awet dalam waktu sangat lama.

4.5. Median Umur Simpan per Kategori dan Metode Penyimpanan

Tujuan penggunaan nilai median dalam analisis ini adalah untuk memberikan gambaran titik tengah data yang representatif dan kebal terhadap pengaruh nilai ekstrem, Karena dataset umur simpan ini memiliki distribusi *right-skewed*, penggunaan rata-rata (*mean*) akan mendistorsi hasil analisis. Oleh karena itu, statistik deskriptif berbasis median diterapkan agar standarisasi ketahanan bahan makanan yang diperoleh tetap objektif dan mencerminkan realitas karakteristik bahan makanan yang sebenarnya.

Tabel 4.6 Median Umur Simpan per Kategori dan Metode Penyimpanan

Kategori Bahan	Suhu Ruangan	Kulkas	Freezer
Sayuran	1	2	180
Bumbu, Saus & Makanan Kalengan	1	3	165
Hidangan laut	2	7	180
Daging	5	7	240
Makanan Tahan Lama di Rak	1	21	120
Produk Susu & Telur	30	180	360
Buah-buahan	120	360	720
Biji-bijian, Kacang-kacangan & Pasta	360	360	720

Berdasarkan hasil analisis diperoleh bahwa metode penyimpanan terbukti sangat mempengaruhi ketahanan bahan makanan lintas kategori. Kelompok pangan kering seperti Makanan Tahan Lama di Rak serta Biji-bijian, Kacang-kacangan & Pasta secara konsisten memiliki ketahanan tertinggi di semua metode dengan median mencapai 720 hari di dalam *freezer*. Sebaliknya, kelompok pangan segar seperti Hidangan laut, Daging, dan Produk Susu & Telur merupakan komoditas yang paling rentan rusak (*highly perishable*) karena hanya mampu

bertahan sekitar 1 hari di suhu ruangan. Meskipun demikian, perpindahan ke metode pembekuan (*freezer*) secara radikal mampu mendongkrak daya tahan seluruh kategori pangan segar ini hingga hitungan ratusan hari, yang menegaskan bahwa *freezer* merupakan intervensi penyimpanan paling efektif untuk pengawetan jangka panjang bagi hampir seluruh jenis bahan makanan.

4.6. Distribusi Jumlah Bahan per Resep

Distribusi jumlah bahan per resep digunakan untuk memahami tingkat kompleksitas resep dalam dataset serta mengetahui karakteristik jumlah bahan yang digunakan pada setiap resep sebagai dasar pengembangan sistem rekomendasi yang lebih relevan dan sesuai dengan ketersediaan bahan pengguna.

Tabel 4.7 Distribusi Jumlah Bahan per Resep

Statistik	Nilai
Jumlah Resep	11790
Mean	10.4
Standar Deviasi	5.3
Min	1
Quartil 1	7
Median	10
Quartil 3	13
Max	51

Kategori Resep	Jumlah Resep
Jumlah Resep	1093
Mean	770
Standar Deviasi	4377
Min	5550

Berdasarkan hasil analisis terhadap 11.790 resep, diperoleh rata-rata jumlah bahan sebesar 10,4 bahan per resep dengan median 10 bahan. Hal ini menunjukkan bahwa sebagian besar resep dalam dataset membutuhkan sekitar 10 bahan untuk dibuat. Nilai standar deviasi sebesar 5,3 menunjukkan adanya variasi jumlah bahan yang cukup besar antar resep, di mana terdapat resep sederhana dengan hanya 1 bahan hingga resep kompleks dengan 51 bahan. Distribusi kategori resep menunjukkan bahwa mayoritas resep berada pada kategori lebih dari 10 bahan, yaitu sebanyak 5.550 resep, diikuti kategori 6–10 bahan sebanyak 4.377 resep. Sementara itu, resep dengan bahan yang sangat sedikit, yaitu kurang dari 3 bahan, berjumlah 1.093 resep. Hasil analisis ini menunjukkan bahwa sebagian besar resep pada dataset tergolong cukup kompleks karena memerlukan banyak bahan.

4.7. Analisis Frekuensi Bahan pada Dataset Resep

Analisis frekuensi kemunculan bahan adalah untuk mengetahui bahan yang paling sering digunakan dalam dataset resep sehingga dapat membantu memahami pola penggunaan bahan serta mendukung pengembangan sistem rekomendasi resep pada project SisaBisa.

Tabel 4.8 Bahan Paling Sering Muncul di Resep

No	Bahan	Frekuensi
1	Bawang Putih	8915
2	Garam	8044
3	Bawang Merah	7053
4	Penyedap Rasa	5322
5	Cabai Rawit	4632

Tabel 4.9 Bahan Utama Paling Sering Muncul di Resep

No	Bahan	Frekuensi
1	Telur Ayam	2901
2	Tahu	1792
3	Ayam	1680
4	Tempe	1543
5	Wortel	1236


Hasil analisis menunjukkan bahwa bahan seperti bawang putih, garam, dan bawang merah merupakan bahan yang paling sering muncul dalam resep karena termasuk bumbu dasar yang umum digunakan. Setelah bumbu dasar dikecualikan, bahan utama yang paling dominan adalah telur ayam, tahu, ayam, dan tempe. Hal ini menunjukkan bahwa dataset resep didominasi oleh bahan makanan yang

umum digunakan dalam masakan sehari-hari, sehingga sistem rekomendasi dapat lebih difokuskan pada bahan yang paling sering dimiliki pengguna.

BAB V. VISUALISASI DAN EXPLANATORY ANALYSIS

5.1. Estimasi Umur Simpan Rata-rata per Metode Penyimpanan

Visualisasi ini digunakan untuk memberikan gambaran mengenai pola persebaran umur simpan bahan makanan pada setiap metode penyimpanan, yaitu suhu ruangan, kulkas, dan *freezer*, sehingga dapat diketahui metode penyimpanan yang paling efektif dalam memperpanjang umur simpan bahan makanan.




Berdasarkan visualisasi estimasi umur simpan per metode penyimpanan, terlihat bahwa metode penyimpanan berpengaruh terhadap lama daya simpan bahan makanan. Penyimpanan pada suhu ruangan memiliki rata-rata umur simpan sekitar 62 hari dengan median 2 hari, sedangkan penyimpanan menggunakan kulkas memiliki rata-rata sekitar 95 hari dengan median 7 hari. Sementara itu, *freezer* memiliki estimasi umur simpan paling tinggi, yaitu rata-rata sekitar 285 hari dengan median 180 hari. Hasil ini menunjukkan bahwa *freezer* merupakan metode

penyimpanan paling efektif untuk memperpanjang umur simpan bahan makanan dibandingkan kulkas maupun suhu ruangan.

Selain itu, boxplot menunjukkan adanya persebaran data yang cukup lebar dan beberapa outlier pada setiap metode penyimpanan, yang menandakan bahwa setiap bahan memiliki karakteristik daya simpan yang berbeda. Kurva distribusi juga menunjukkan bahwa sebagian besar bahan memiliki umur simpan pendek hingga menengah, sementara hanya sebagian kecil bahan yang mampu bertahan sangat lama. Oleh karena itu, hasil analisis ini dapat membantu project SisaBisa dalam memberikan rekomendasi penyimpanan yang lebih optimal untuk mengurangi potensi food waste.

5.2. Kategori Bahan dengan Risiko Kedaluwarsa Tertinggi

Visualisasi ini menyajikan gambaran umum mengenai median umur simpan bahan makanan yang dikelompokkan berdasarkan kategori komoditasnya untuk seluruh metode penyimpanan. Melalui grafik ini, kita dapat memetakan karakteristik daya tahan masing-masing jenis makanan serta mengidentifikasi tingkat risiko pembusukan, mulai dari komoditas yang sangat rentan (risiko tinggi) hingga bahan makanan yang memiliki stabilitas penyimpanan jangka panjang (risiko rendah).




Berdasarkan grafik Median Umur Simpan per Kategori (Semua Metode Penyimpanan), terlihat jelas adanya diferensiasi durasi simpan dan tingkat risiko yang signifikan di antara berbagai kelompok bahan makanan. Hidangan laut menjadi kategori bahan yang paling cepat kedaluwarsa dengan median umur simpan hanya 2 hari, diikuti oleh Daging dengan median 3 hari. Hal ini menunjukkan bahwa bahan protein hewani segar masuk dalam kategori risiko tinggi (≤ 7 hari) dan memiliki risiko kerusakan paling besar dibanding kategori lainnya, terutama jika tidak segera disimpan atau diolah dengan benar. Bergeser ke kelompok risiko sedang (8–30 hari), produk segar nabati seperti Sayuran dan Buah-buahan memiliki karakteristik ketahanan yang identik dengan median umur simpan masing-masing 14 hari, sementara Produk Susu & Telur menunjukkan daya tahan yang sedikit lebih lama dengan median 30 hari.

Sebaliknya, kelompok komoditas yang masuk dalam kategori risiko rendah (> 30 hari) didominasi oleh bahan makanan kering dan produk awetan. Kategori seperti Biji-bijian, Kacang-kacangan & Pasta serta Bumbu, Saus & Makanan

Kalengan memiliki median umur simpan jauh lebih panjang yaitu 180 hari, dan durasi paling maksimal dicapai oleh Makanan Tahan Lama di Rak yang mampu menyentuh median hingga 365 hari. Perbedaan kontras ini membuktikan bahwa karakteristik alami dan jenis bahan sangat memengaruhi estimasi umur simpan serta tingkat risiko *food waste*. Oleh karena itu, hasil analisis data ini dapat dimanfaatkan secara praktis dalam menyusun sistem prioritas memasak, di mana bahan dengan umur simpan paling pendek seperti hidangan laut, daging, sayuran, dan produk susu sebaiknya diprioritaskan untuk digunakan terlebih dahulu guna mengurangi potensi pemborosan makanan di tingkat rumah tangga maupun industri.

5.3. Pengaruh Metode Penyimpanan terhadap Umur Simpan

Visualisasi ini menyajikan analisis statistik inferensial untuk membuktikan secara empiris pengaruh metode penyimpanan terhadap daya tahan bahan makanan. Melalui rangkaian uji statistik ini, kita dapat memetakan distribusi umur simpan pada metode suhu ruangan, kulkas, dan *freezer*, sekaligus menguji apakah perbedaan durasi simpan di antara metode-metode tersebut bersifat signifikan atau nyata secara ilmiah.



Berdasarkan hasil uji Kruskal-Wallis, diperoleh nilai *H-statistic* sebesar 200,3987 dengan *p-value* sebesar $3,05 \times 10^{-44}$. Karena nilai *p-value* tersebut jauh


lebih kecil dari taraf signifikansi $\alpha = 0,05$, hal ini menunjukkan bahwa metode penyimpanan memiliki pengaruh yang sangat signifikan terhadap umur simpan bahan makanan. Dengan kata lain, terdapat perbedaan umur simpan yang nyata antara penyimpanan di suhu ruangan, kulkas, dan *freezer*. Visualisasi distribusi juga memperlihatkan bahwa *freezer* memiliki median umur simpan paling tinggi, yaitu 180 hari, sedangkan suhu ruangan dan kulkas memiliki median jauh lebih rendah, masing-masing hanya 2 hari dan 7 hari.

Selain itu, hasil uji lanjut menggunakan *Post-hoc* Mann-Whitney U menunjukkan bahwa seluruh pasangan kombinasi metode penyimpanan memiliki *p-value* sebesar 0,0000 ($p < 0,05$), sehingga dapat dipastikan setiap metode penyimpanan berbeda signifikan satu sama lain. Hasil analisis ini memperkuat kesimpulan bahwa pemilihan metode penyimpanan merupakan faktor krusial dalam memperpanjang umur simpan bahan makanan. Data empiris ini sekaligus dapat digunakan sebagai dasar yang kuat dalam menyusun sistem rekomendasi penyimpanan yang tepat guna mengurangi potensi pemborosan makanan (*food waste*).

5.4. Distribusi dan Keseimbangan Dataset

Visualisasi ini menyajikan pemeriksaan ketidakseimbangan kelas (*class imbalance check*) terhadap struktur dataset yang digunakan dalam penelitian. Melalui grafik *donut chart* dan *horizontal bar chart* ini, kita dapat mengevaluasi proporsi serta sebaran jumlah data, baik berdasarkan metode penyimpanan maupun kategori bahan makanan, guna memastikan bahwa data yang dianalisis memiliki keterwakilan yang seimbang dan bebas dari bias pemodelan.

Class Imbalance Check: Distribusi Data per Storage & Kategori




Berdasarkan visualisasi distribusi data di atas, jumlah sampel pada setiap metode penyimpanan terbagi secara sangat seimbang, di mana metode suhu ruangan, kulkas, dan *freezer* masing-masing memiliki proporsi tepat 33,3% dari total 504 data. Kondisi ini menunjukkan bahwa dataset sama sekali tidak mengalami isu *class imbalance* pada variabel metode penyimpanan, sehingga analisis komparatif maupun model prediktif yang dibangun nantinya tidak akan bias terhadap salah satu metode penyimpanan tertentu.

Namun, jika meninjau distribusi data berdasarkan kategori bahan makanan, terlihat adanya ketidakseimbangan jumlah data antar-komoditas. Kategori Sayuran mendominasi dataset dengan jumlah sampel paling banyak mencapai 177 data, diikuti oleh Bumbu, Saus & Makanan Kalengan (78 data) dan Hidangan laut (75 data) yang masuk dalam kategori representatif (≥ 50 data). Di sisi lain, kategori seperti Daging (42 data), Produk Susu & Telur (39 data), Makanan Tahan Lama di Rak (39 data), Buah-buahan (33 data), serta Biji-bijian, Kacang-kacangan & Pasta (21 data) memiliki jumlah sampel yang lebih sedikit namun masih berada pada batas rentang yang cukup aman dan cukup representatif (20–49 data) untuk dianalisis. Secara keseluruhan, hasil evaluasi ini menegaskan bahwa karakteristik dataset sudah sangat baik dan valid untuk mendukung analisis umur simpan, khususnya

dalam mengeksplorasi interaksi antara metode penyimpanan dan variasi kategori pangan secara objektif.

5.5. Frekuensi Penggunaan Bahan dalam Resep

Visualisasi ini menampilkan analisis frekuensi kemunculan bahan pangan di dalam kumpulan resep masakan untuk memetakan karakteristik dan pola konsumsi kuliner. Melalui perbandingan dua grafik batang horizontal ini, kita dapat mengidentifikasi jenis bumbu dasar yang paling mendominasi komponen masakan secara keseluruhan, sekaligus mendeteksi bahan makanan utama yang paling populer digunakan oleh masyarakat setelah bumbu-bumbu dasar tersebut dikecualikan.




Berdasarkan analisis frekuensi bahan dalam resep, terlihat jelas bahwa bawang putih (8.915 kemunculan), garam (8.044 kemunculan), dan bawang merah (7.053 kemunculan) menjadi bahan yang paling mutlak sering digunakan dalam masakan. Pola ini membuktikan bahwa sebagian besar resep memiliki kesamaan fondasi cita rasa yang sangat bergantung pada perpaduan rempah aromatik dan penyedap dasar. Selain trio komoditas utama tersebut, tingginya intensitas penggunaan penyedap rasa, cabai rawit, lada putih, jahe, hingga lengkuas

mencerminkan dengan kuat identitas kuliner lokal yang kaya akan rempah dan cenderung menonjolkan cita rasa yang tajam serta berani.

Di sisi lain, ketika bumbu dasar dieksklusi dari pemetaan untuk melihat bahan inti masakan, telur ayam menempati urutan teratas dengan frekuensi mencapai 2.901 kemunculan, disusul oleh komoditas populer lain seperti tahu (1.792), ayam (1.680), dan tempe (1.543). Tingginya angka kemunculan ini menandakan bahwa sumber protein yang praktis, ekonomis, serta mudah diolah merupakan komoditas utama yang paling dicari untuk menu sehari-hari. Munculnya beberapa jenis sayuran pendukung seperti wortel, kentang, seledri, dan kubis di barisan berikutnya juga mengindikasikan tingginya frekuensi hidangan yang mengombinasikan protein dengan sayur pelengkap. Secara praktis, temuan dari distribusi data ini sangat potensial untuk diaplikasikan ke dalam sistem rekomendasi resep; bahan-bahan dengan frekuensi tinggi ini mencerminkan apa yang biasanya selalu tersedia (*stock*) di dapur pengguna, sehingga rekomendasi menu yang dihasilkan sistem nantinya akan jauh lebih relevan, aplikatif, dan realistis untuk dieksekusi sehari-hari.

5.6. Kompleksitas Resep Berdasarkan Jumlah Bahan

Visualisasi ini menyajikan analisis mengenai kompleksitas resep masakan berdasarkan kuantitas komponen yang digunakan di dalamnya. Melalui grafik distribusi frekuensi dan pengelompokan berdasarkan wadah data (*bucket* jumlah bahan) ini, kita dapat mengevaluasi tingkat keragaman bahan dalam setiap formula masakan, guna memahami derajat kemudahan atau kerumitan persiapan kuliner yang mendominasi dataset.



Berdasarkan grafik distribusi jumlah bahan per resep, diperoleh nilai rata-rata (*mean*) sebesar 10,4 bahan dengan nilai tengah (*median*) tepat pada 10 bahan. Kedekatan nilai antara rata-rata dan median ini mengindikasikan bahwa mayoritas resep dalam dataset berkumpul secara konsisten pada tingkat kompleksitas menengah, walaupun keberadaan beberapa resep ekstrem dengan jumlah bahan yang sangat melimpah (mencapai lebih dari 40-50 bahan) membuat kurva distribusi memiliki ekor yang sedikit condong ke kanan (*right-skewed*). Fenomena variasi ini dipertegas oleh grafik distribusi berdasarkan *bucket* jumlah bahan, di mana mayoritas resep secara dominan terkonsentrasi pada kelompok > 10 bahan yaitu sebanyak 5.550 resep (47,1%) dan disusul rapat oleh kategori 6–10 bahan sebanyak 4.377 resep (37,1%). Sebaliknya, resep dengan formulasi sederhana yang hanya memanfaatkan 3–5 bahan (6,5%) maupun < 3 bahan (9,3%) mencakup porsi yang relatif kecil dari keseluruhan data.

Hasil analisis ini menunjukkan bahwa sebagian besar resep masakan Indonesia cenderung menggunakan variasi bahan yang cukup banyak dan kompleks. Temuan ini menjadi poin penting dalam pengembangan sistem rekomendasi resep, karena jumlah bahan yang digunakan akan memengaruhi tingkat kesulitan memasak, estimasi waktu persiapan, serta kemungkinan ketersediaan bahan-bahan tersebut di rumah tangga pengguna.

BAB VI. A/B TEST SIMULATION

6.1. Latar Belakang dan Desain Eksperimen

SisaBisa merupakan platform yang dirancang untuk membantu pengguna mengelola stok bahan makanan serta mengurangi potensi *food waste* melalui fitur rekomendasi resep. Salah satu fitur utama yang dikembangkan adalah rekomendasi resep berbasis prioritas bahan cepat kedaluwarsa, yaitu sistem yang memprioritaskan bahan dengan estimasi umur simpan paling pendek agar segera digunakan sebelum terbuang. Untuk mengevaluasi efektivitas fitur tersebut, dilakukan simulasi A/B testing dengan membandingkan dua strategi rekomendasi resep yang berbeda. Strategi pertama menggunakan rekomendasi resep populer seperti yang umum digunakan pada aplikasi resep makanan, sedangkan strategi kedua menggunakan rekomendasi resep berdasarkan bahan yang memiliki risiko kedaluwarsa lebih tinggi.

Eksperimen dilakukan dengan membagi pengguna ke dalam dua grup, yaitu grup Control dan grup Treatment. Kedua grup menerima strategi rekomendasi yang berbeda untuk dibandingkan efektivitasnya. Adapun desain eksperimen yang digunakan ditunjukkan pada Tabel 5.1.

Tabel 5.1 Desain Eksperimen A/B Testing

Grup	Strategi Rekomendasi
Control (A)	Rekomendasi resep populer berdasarkan bahan umum
Treatment (B)	Rekomendasi resep berdasarkan bahan cepat kedaluwarsa

Pada grup Control, pengguna menerima rekomendasi resep populer tanpa mempertimbangkan umur simpan bahan makanan. Sementara itu, grup Treatment menerima rekomendasi resep yang memprioritaskan bahan dengan estimasi umur simpan paling pendek agar bahan lebih cepat digunakan.

Metrik utama yang digunakan dalam eksperimen ini adalah *cook rate*, yaitu proporsi pengguna yang memilih atau memasak resep setelah menerima rekomendasi dari sistem.

$$\text{Cook Rate} = \frac{\text{Jumlah User yang Memasak}}{\text{Total User}}$$

Semakin tinggi *cook rate* yang diperoleh, maka strategi rekomendasi dianggap semakin efektif dalam mendorong pengguna untuk memasak resep yang direkomendasikan.

6.2. Perumusan Hipotesis

Karena metrik yang diuji berbentuk proporsi atau data biner, yaitu pengguna memasak resep atau tidak memasak resep, maka metode statistik yang digunakan adalah Two-Proportion Z-Test.

Hipotesis yang digunakan dalam eksperimen ini adalah sebagai berikut.

$$H_0: p_{\text{control}} = p_{\text{treatment}}$$

$$H_1: p_{\text{treatment}} > p_{\text{control}}$$

Hipotesis nol (H_0) menyatakan bahwa tidak terdapat perbedaan *cook rate* antara rekomendasi resep populer dan rekomendasi berbasis bahan cepat kedaluwarsa. Sementara itu, hipotesis alternatif (H_1) menyatakan bahwa *cook rate* pada grup Treatment lebih tinggi dibanding grup Control.

Dengan kata lain, eksperimen ini dilakukan untuk menguji apakah rekomendasi berbasis prioritas bahan cepat kedaluwarsa lebih efektif dalam meningkatkan tindakan memasak pengguna.

6.3. Perhitungan Kebutuhan Sampel

Sebelum simulasi dilakukan, terlebih dahulu dihitung jumlah minimum sampel yang dibutuhkan untuk masing-masing grup eksperimen menggunakan pendekatan *sample size* untuk perbandingan dua proporsi.

Asumsi yang digunakan dalam eksperimen adalah sebagai berikut:

- Baseline *cook rate* pada grup Control = 28%
- Target *cook rate* pada grup Treatment = 36%
- Significance level (α) = 0.05
- Statistical power = 80%

Berdasarkan hasil perhitungan, diperoleh kebutuhan minimum sampel sebesar 420 pengguna untuk setiap grup. Dengan demikian, total pengguna yang digunakan dalam simulasi eksperimen adalah 840 pengguna. Jumlah sampel tersebut dianggap cukup untuk mendeteksi perbedaan *cook rate* antara kedua strategi rekomendasi dengan tingkat kepercayaan yang memadai.

6.4. Simulasi Data Pengguna

Aplikasi SisaBisa belum memiliki data pengguna aktual sehingga eksperimen dilakukan menggunakan simulasi data perilaku pengguna. Simulasi tersebut merepresentasikan kemungkinan tindakan pengguna setelah menerima rekomendasi resep dari sistem. Jumlah pengguna pada grup Control dan Treatment dibuat seimbang, yaitu masing-masing sebanyak 420 pengguna. Grup Control diberikan probabilitas *cook rate* sebesar 28%, sedangkan grup Treatment diberikan probabilitas *cook rate* sebesar 36%. Dataset simulasi terdiri atas beberapa atribut utama sebagaimana ditunjukkan pada Tabel 5.2.

Tabel 5.2 Struktur Dataset Simulasi


Kolom	Deskripsi
user_id	ID unik pengguna
group	Grup eksperimen pengguna
recommended_strategy	Jenis strategi rekomendasi yang

	diterima
cooked_recipe	Status pengguna memasak resep (1 = memasak, 0 = tidak)

Data simulasi digunakan untuk menghitung *cook rate* pada masing-masing grup serta melakukan pengujian statistik terhadap perbedaan performa kedua strategi rekomendasi.

6.5. Analisis Cook Rate

Hasil simulasi menunjukkan bahwa grup Treatment memiliki *cook rate* lebih tinggi dibandingkan grup Control.



Gambar 5.1 Perbandingan *Cook Rate* antara Grup Control dan Treatment

Visualisasi hasil eksperimen menunjukkan bahwa grup Treatment yang menerima rekomendasi resep berbasis bahan cepat kedaluwarsa memiliki *cook rate* sebesar 33.57%, sedangkan grup Control yang menerima rekomendasi resep populer memiliki *cook rate* sebesar 28.10%. Perbedaan tersebut menunjukkan bahwa pengguna pada grup Treatment cenderung lebih tertarik untuk memilih atau memasak resep yang direkomendasikan oleh sistem. Strategi rekomendasi berbasis prioritas bahan cepat kedaluwarsa secara visual terlihat lebih efektif dibandingkan rekomendasi resep populer biasa.

Perbedaan yang terlihat secara visual belum cukup untuk dijadikan dasar kesimpulan yang valid. Pengujian statistik tetap diperlukan untuk memastikan apakah perbedaan *cook rate* tersebut benar-benar signifikan atau hanya terjadi secara kebetulan.

6.6. Pengujian Statistik Two-Proportion Z-Test

Pengujian signifikansi perbedaan *cook rate* antara grup Control dan Treatment dilakukan menggunakan metode Two-Proportion Z-Test. Statistik uji dihitung berdasarkan selisih proporsi *cook rate* antara grup Treatment dan grup Control yang dinormalisasi menggunakan standard error dari kedua proporsi. Hasil pengujian statistik ditunjukkan pada Tabel 5.3.

Tabel 5.3 Hasil Two-Proportion Z-Test

Metrik	Nilai
Cook Rate Control	28.10%
Cook Rate Treatment	33.57%
Z-statistic	1.7184
P-value	0.0429

Kriteria pengambilan keputusan pada eksperimen ini adalah sebagai berikut.

- Jika $p\text{-value} < 0.05$, maka H_0 ditolak
- Jika $p\text{-value} \geq 0.05$, maka H_0 gagal ditolak

Nilai $p\text{-value}$ sebesar 0.0429 lebih kecil dari 0.05 sehingga H_0 ditolak. Hasil tersebut menunjukkan bahwa terdapat bukti statistik bahwa rekomendasi resep berbasis bahan cepat kedaluwarsa memiliki *cook rate* lebih tinggi dibandingkan rekomendasi resep populer biasa.

Strategi rekomendasi berbasis prioritas bahan cepat kedaluwarsa terbukti lebih efektif dalam meningkatkan tindakan memasak pengguna pada simulasi eksperimen yang dilakukan.

6.7. Analisis Dampak Bisnis

Analisis dampak bisnis dilakukan untuk mengukur besarnya peningkatan performa yang dihasilkan oleh strategi Treatment. Hasil perhitungan dampak bisnis ditunjukkan pada Tabel 5.4.

Tabel 5.4 Analisis Dampak Bisnis

Metrik	Nilai
Absolute Difference	5.48 percentage points
Relative Lift	19.49%

Strategi rekomendasi berbasis bahan cepat kedaluwarsa memberikan peningkatan *cook rate* sebesar 5.48 poin persentase dibandingkan strategi rekomendasi populer biasa. Nilai *relative lift* sebesar 19.49% menunjukkan adanya peningkatan performa yang cukup signifikan dari sisi perilaku pengguna. Hasil tersebut mengindikasikan bahwa pengguna lebih terdorong untuk memasak bahan

yang perlu segera digunakan ketika sistem memberikan rekomendasi yang relevan dengan kondisi stok bahan mereka.

Hasil eksperimen mendukung pengembangan fitur-fitur utama pada SisaBisa, antara lain sebagai berikut.

- Kulkas Virtual untuk memantau stok bahan makanan
- Prioritas Masak berdasarkan estimasi umur simpan
- Rekomendasi resep berdasarkan bahan yang perlu segera digunakan
- Pengurangan potensi *food waste* rumah tangga

Strategi rekomendasi berbasis umur simpan bahan berpotensi menjadi nilai utama aplikasi SisaBisa dalam membantu pengguna mengelola bahan makanan secara lebih efektif dan berkelanjutan.

6.8. Kesimpulan A/B Testing

Hasil simulasi A/B testing menunjukkan bahwa grup Treatment yang menerima rekomendasi resep berdasarkan bahan cepat kedaluwarsa memiliki *cook rate* lebih tinggi dibandingkan grup Control yang menerima rekomendasi resep populer biasa.

Hasil pengujian statistik menunjukkan nilai *p-value* sebesar 0.0429 yang lebih kecil dari 0.05 sehingga H_0 ditolak. Kondisi tersebut menunjukkan bahwa rekomendasi berbasis prioritas bahan cepat kedaluwarsa terbukti secara statistik lebih efektif dalam meningkatkan tindakan memasak pengguna dibandingkan rekomendasi resep populer biasa.

Nilai *relative lift* sebesar 19.49% menunjukkan adanya peningkatan performa rekomendasi pada grup Treatment. Hasil eksperimen mendukung pengembangan fitur rekomendasi resep berbasis umur simpan bahan sebagai salah satu fitur utama pada sistem SisaBisa untuk membantu mengurangi potensi *food waste* rumah tangga.

BAB VII. KESIMPULAN

Berdasarkan tahapan analisis data yang telah dilakukan, dapat disimpulkan bahwa hasil EDA, *explanatory analysis*, dan A/B testing memberikan dasar yang kuat untuk pengembangan fitur utama pada proyek SisaBisa. Analisis menunjukkan bahwa metode penyimpanan dan kategori bahan memiliki pengaruh signifikan terhadap umur simpan bahan makanan. Bahan seperti hidangan laut, daging, sayuran, dan produk susu memiliki risiko kedaluwarsa lebih tinggi sehingga perlu diprioritaskan dalam sistem rekomendasi resep. Selain itu, analisis frekuensi bahan menunjukkan bahwa bahan seperti telur, tahu, ayam, dan tempe merupakan bahan yang paling sering digunakan dalam resep sehari-hari sehingga dapat menjadi fokus utama dalam pengembangan model rekomendasi resep agar hasil rekomendasi lebih relevan dengan kondisi inventori pengguna.

Analisis kompleksitas resep juga menunjukkan bahwa sebagian besar resep menggunakan sekitar 10 bahan, sehingga sistem rekomendasi perlu mempertimbangkan jumlah bahan yang realistis agar resep yang diberikan tetap mudah dieksekusi pengguna. Hasil A/B testing membuktikan bahwa rekomendasi resep berbasis prioritas bahan cepat kedaluwarsa menghasilkan *cook rate* lebih tinggi dibanding rekomendasi resep populer biasa dengan *relative lift* sebesar 19,49%. Hal ini menunjukkan bahwa pendekatan AI berbasis prioritas *expiry* lebih efektif dalam mendorong pengguna memanfaatkan bahan makanan sebelum terbuang.

Hasil analisis mendukung pengembangan fitur inventori bahan makanan, sistem prioritas bahan berdasarkan estimasi masa kedaluwarsa, notifikasi pengingat sebelum bahan kedaluwarsa, serta fitur rekomendasi resep otomatis dari bahan prioritas. Selain itu, integrasi Generative AI untuk menampilkan estimasi

kalori dan informasi nutrisi dapat meningkatkan nilai informasi dan pengalaman pengguna dalam menggunakan sistem. Secara keseluruhan, hasil analisis menunjukkan bahwa SisaBisa memiliki potensi sebagai solusi berbasis AI yang mampu membantu pengguna mengelola bahan makanan secara lebih efisien sekaligus mengurangi potensi *food waste* rumah tangga.